

TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



SPERM MORFOLOJİ ANALİZİ İÇİN CNN MODELİ
OLUŞTURMA

18011615 – Abdurrahman Ebrar YÜCEL

—

BİLGİSAYAR PROJESİ

Danışman
Dr. Öğr. Üyesi Hamza Osman İLHAN

Ocak, 2021

İÇİNDEKİLER

ŞEKİL LİSTESİ	iii
TABLO LİSTESİ	iv
1 Özet	1
2 Giriş	2
3 Ön İnceleme	4
4 Fizibilite	6
4.1 Teknik Fizibilite	6
4.2 Zaman Fizibilitesi	6
4.3 Yasal Fizibilite	6
4.4 Ekonomik Fizibilite	6
5 Sistem Analizi	7
6 Sistem Tasarımı	9
7 Deneysel Sonuçlar ve Performans Analizi	14
8 Sonuç	17
9 Referanslar	18

ŞEKİL LİSTESİ

Şekil 2.1	How Convolutional Neural Network works	3
Şekil 5.1	Dataset Structure	7
Şekil 5.2	Number of Images	8
Şekil 6.1	Model 1	11
Şekil 6.2	Model 2	12
Şekil 6.3	Inception Module with Dimension Reduction	13
Şekil 7.1	SMIDS Test Sonuçları	15
Şekil 7.2	HuSHeM Test Sonuçları	16
Şekil 7.3	SCIAN Test Sonuçları	16

TABLO LİSTESİ

Tablo 6.1	Hyperparameters of Models	10
Tablo 7.1	Average Training Times	15

1

Özet

Tıbbi görüntü analizi, teknolojinin gelişmesiyle sağlık alanında gittikçe kullanışlı bir hale gelmektedir. Evrimsel sinir ağları da tıbbi görüntü analizinde kullanılan yöntemlerden biridir. Kısırlık tanısı konan çiftler için son derece önemli bir konu olan sperm morfolojisi, kısırlığa neden olan unsurların araştırılması sırasında sperm analizinin yapılmasına ihtiyaç duyar. Bu analiz sırasında spermelerde yapı bozukluğu incelenir. Özellikle spermin başının boyutu ve şekli analizde çok etkilidir. Elde edilen sonuçlar doktorların tedavi ve teşhis sırasında ne şekilde bir yol izleyeceğini gösterir bundan dolayı büyük önem teşkil eder. Bu projede HuSHeM, SCIAN-Morpho, SMIDS verisetleri kullanılarak sperm görüntülerinin sınıflandırılması için uygun evrimsel sinir ağı modellerinin oluşturulması amaçlanmaktadır.

2 Giriş


Sperm kısaca erkek bireylerin üreme hücresidir. Erkek bireylerin ergenlik dönemine girmesiyle testislerde üretimine başlanır. Sperm hücresi yaklaşık santimetrenin 250'de biri uzunluğundadır ve baş, boyun, gövde ve kuyruk olmak üzere üç kısımdan oluşur. Baş kısmı sperm hücresinin yumurta hücresiyle birleşmesini sağlar, gövde kısmı kişinin genetik materyalini içerir, kuyruk kısmı ise sperm hücresinin hareketliliğini sağlar.

Kısırlık, üreme sisteminin işlevini bozan bir sağlık sorunudur. Üreme yaşlarındaki her 100 çiftten yaklaşık yüzde 10 unda kısırlık sorunuyla karşılaşılmaktadır ve bu sorunun yüzde 30 u erkek ile ilgilidir. Kısırlığın bir sebebi veya bir çok sebebi olabilmektedir. Erkeklerde kısırlığın başlıca sebepleri sperm üretiminde ve sperm hareketinde azalma, kanal tıkanıklıkları, enfeksiyonlar, anormal sperm fonksiyonu, genetik sorunlar, sperm morfolojisinin bozukluğu, alkol sigara vs. olarak gösterilebilir. Erkeklerde kısırlığın başlıca tanı yöntemi semen analizi (spermioqram) dir. Semen analizi kişilerden alınan sperm örneklerinde sperm sayısı, hareketliliği ve yapısı incelenerek yapılır. Bu incelemenin en önemli kısımlarından biri ise sperm morfolojisinin incelenmesidir.

Sperm morfolojisi incelenirken, günümüzde görsel bilginin analizi konusunda yüksek başarımla elde edilebilen evrişimli sinir ağları yapısının kullanılması başarılı sonuçlar elde edilmesini sağlayabilir. Evrişimli sinir ağları derin öğrenmenin alt dallarından biridir ve günümüzde resimlerin, videoların tanınması ve sınıflandırılması, tıbbi görünüm analizi, doğal dil işleme alanlarında yaygın olarak kullanılır. Evrişimli sinir ağlarının temelinde doğrusal bir işlem türü olan evrişim işlemi yer alır, bundan dolayı katmanlarının en az bir tanesinde evrişim işlemi yapan sinir ağlarıdır. Evrişimli sinir ağlarında kullanılan katman tipleri şunlardır; giriş katmanı, konvolüsyon katmanı, aktivasyon katmanı, havuzlama katmanı, tam bağlantı katmanı, normalleştirme katmanları, düzenleştirme katmanları, sınıflandırma katmanı. Şekil 2.1 de evrişimli sinir ağlarının çalışma şekli basitçe gösterilmiştir.

Bu çalışmanın amacı SCIAN, HuSHeM, SMIDS verisetlerindeki sperm resimlerinin

özellikleriyle spermilerin morfolojik yapısını yüksek başarımla sınıflandırabilen evrişimli sinir ağı modellerinin oluşturulmasıdır. Ancak modeller oluşturulurken belli başlı zorluklarla karşılaşmaktadır; sperm sınıflarının bazılarının çok benzer olması, düşük boyuttaki sperm görüntülerinin gürültülü olması, düşük boyutlu sperm görüntüleri, kompleks modellerin eğitilmesi için yeterli verinin olmaması ve son olarak sperm sınıflarının eğitim verilerinin dengesiz dağılımı buna örnek olarak verilebilir.



Şekil 2.1 How Convolutional Neural Network works

Today, many studies have been published to classify sperm. Various methods and various data sets have been used in these studies.

Perez-Sanchez et al. They studied ten shape features to find out their relevance to classification of human sperm heads into 14 classes of shapes. These features comprise two sets of head measurements: the first set called basic features (length, width, area, perimeter, and mass) and the second set called derived features (ratio, the difference in length and width, ellipticity, form and total mass). Their method is manual and they used statistical tools to show these features are relevant in discriminating some of the shape classes[13].

Perez-Sanchez et al. investigated the relationship between ten shape features and 14 classes of shapes of human sperm heads. These features are divided into 2 categories: basic features such as length, width, area, perimeter, mass; and derived features such as ratio, the difference in length and width, ellipticity, form, total mass. They used a manual method and statistically showed that these features are related with differentiating some of the shape classes[13].

In 2017 Chang et al. prepared first free and available gold standard data set, "SCIAN-MorphoSpermGS", which analyzes and evaluates morphological classification of sperm heads. This data set uses the categorization of sperm heads for semen analysis in the WHO laboratory manual: "Normal", "Tapered", "Pyriform", "Small", "Amorphous". Sperm head images in the data set were identified by 3 Chilean experts. Chang et al. also suggests CE-SVM which is a two phase analysis pipeline for the morphological classification of sperm heads in the data set[5].

On the other hand, Shaker et al. produced the HuSHeM (Human Sperm Head Morphology) data set with an adaptive dictionary learning based approach. In this approach, the dictionaries are trained to detect those sperm head categories using certain square patches from the sperm head images[7].

In another study Riordon et al. developed another method, a VGG-16 architecture for the classification. In this method, VGG was trained on ImageNet, then fine tuned on SCIAN data set. The results show that this deep learning method may contribute the seminogram in an effective way[6].

In another study, Ilhan et. al used wavelet and descriptor based features in the classification. SMIDS (Sperm Morphology Image Data Set), which is new data set, is introduced by them. They achieved 82 percent and 84 percent accuracies by using Wavelet and SURF features.[9][10].

In another study Ilhan et. al, applied several preprocessing step to eliminate the noisy parts in the image patches. After that, they used SURF and MSER descriptor features to feed a non-linear classification schema, SVM with polynomial kernel. In this way, they increased their classification accuracies in SMIDS data set from 84 percent to 86 percent[8].

In another Ilhan et. al created two different version of mobile platform based deep neural networks for morphological classification of sperm to eliminate the human factor in VA. They aimed to make morphological analysis autonomously and provide short analyzing times. They achieved 77 percent accuracy on HuSHeM data set, 88 percent on SMIDS data set and 67 percent on SCIAN data set[3].

In another study Jianqian et al. categorized human sperm heads into two groups of normal and abnormal using Principle Component Analysis (PCA) combined with K-nearest neighbors algorithm. However, the bias towards the normal class in the results showed that their method was not reliable[11].

In another study by Yi et al. categorized the sperm heads into two groups as normal, small, elongated, megalo. They reconstructed the head contour using the first ten coefficients of Fourier transform of the head contour points. Then they applied the wavelet transform to the enclosed area of the head. They used the root square mean error in transform space between the image and each class of abnormalities to categorize the sperm head[12].

Projenin fizibilitesi; teknik fizibilite, zaman fizibilitesi, yasal fizibilite ve ekonomik fizibilite başlıkları altında çıkarılmıştır.

4.1 Teknik Fizibilite

Bu proje, MATLAB programla diliyle kodlanacaktır. Bu tercihin sebebi MATLAB ortamının CNN modelli derin öğrenme için uygunluğu ve sağladığı kolaylıklardır. Kullanılabilir toolbox'ların çokluğu ve yaygın kullanımından dolayı referans alınabilecek kaynakların fazlalığı bu seçimde etkili olmuştur. 3 adet verisetinden faydalanılmaktadır. Bunlar SMIDS, HuSHem, SCIAN-Morpho'dur.

4.2 Zaman Fizibilitesi

Projenin tamamlanma süresi, projenin onaylanması itibariyle 90 iş günü olarak hesaplanmıştır.

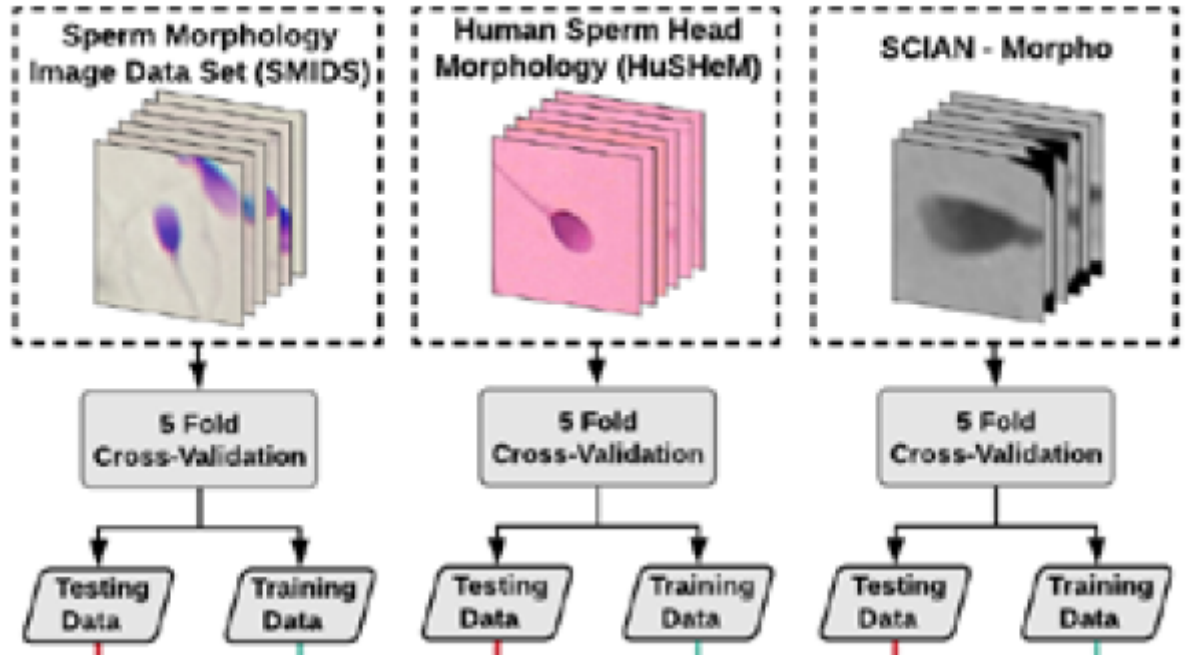
4.3 Yasal Fizibilite

Projenin yapılabilmesi adına bölüm başkanlığından izinler alınmıştır. Projenin gerçekleştirildiği geliştirme ortamları, gerekli izinleri Yıldız Teknik Üniversitesi öğrencilerine sağlamaktadır. Projede kullanılan MATLAB platformu lisanslıdır. Projenin yasalara uygunluğunu bozacak herhangi bir durum tespit edilememiştir.

4.4 Ekonomik Fizibilite

Projede kullanılan platformlar ve diğer kaynaklar MATLAB tarafından Yıldız Teknik Üniversitesi öğrencilerine ücretsiz sunulmaktadır.

5 Sistem Analizi



Şekil 5.1 Dataset Structure

Oluşturulan evrişimli sinir ağı modelleri eğilirken 3 farklı veriseti kullanılacaktır,bunlarda HuSHeM(Human Sperm Head Morphology),SMIDS(Sperm Morphology Image Data Set),SCIAN-Morpho verisetleridir. Verisetleri orjinal setlerle birlikte belirli bir oranda veri artırma işlemi uygulanarak elde edilen setlerden oluşmaktadır. Her bir set 5 katlamalı çapraz doğrulama(5-fold cross validation) işlemi amacıyla 5'e ayrılmıştır,ayrılan her kısım test ve eğitim verilerinden oluşmaktadır.Verisetlerinin yapısı şekil 5.1 de görülmektedir. SCIAN veriseti yaklaşık 35x35 boyutunda resimlerden oluşmaktadır.5 farklı sınıftan 1132 resim içermektedir,sınıflar şöyledir:"Normal","Tapered","Pyriform", "Amorphous","Small".SCIAN verisetinde resimlerin sınıflar arası dengesiz dağılımı mevcut durumdadır,"Amorphous" sınıfına ait veri sayısı diğer sınıflara nazaran fazladır.

HuSHeM veriseti yaklaşık 130x130 boyutunda resimlerden oluşmaktadır.4 farklı sınıftan 216 resim içermektedir, sınıflar şöyledir: "Normal", "Tapered", "Pyriform", "Amorphous".Sınıflara ait veriler hemen hemen dengeli dağılmış durumdadır.SMIDS veriseti ise boyu ve genişliği 150-200 piksel arası değişen boyutlara sahip resimlerden oluşmaktadır.3 farklı sınıftan 3000 resim içermektedir,sınıflar ise şöyledir:"Normal", "Abnormal", "Non-Sperm".Sınıflara ait veriler hemen hemen dengeli dağılmış durumdadır.Orijinal veri setlerinin verilerinin sınıf dağılımları şekil 5.2 de verilmiştir.Modellerin eğitiminde veri arttırma işleminin etkilerinin gözlemlenmesi için orjinal verisetlerinin üzerlerinde ölçeklendirme,kaydırma,döndürme,kırpma vb. işlemler ile belli oranda veri arttırma uygulanarak başarımın artması amaçlanmıştır. Bu çalışmada testler yapılırken HuSHeM verisetinde 1x(orjinal),5x,10x arttırılmış,SCIAN verisetinde 1x,5x,9x arttırılmış ve dengelenmiş,SMIDS verisetinde 1x,5x,8x arttırılmış veriler kullanılmıştır.

SMIDS		HuSHeM		SCIAN-Morpho	
Labels	#	Labels	#	Labels	#
Normal	1021	Normal	54	Normal	100
Abnormal	1005	Tapered	53	Tapered	228
Non-Sperm	974	Pyriform	57	Pyriform	76
		Amorphous	52	Small	72
				Amorphous	656
Total	3000	Total	216	Total	1132

Şekil 5.2 Number of Images

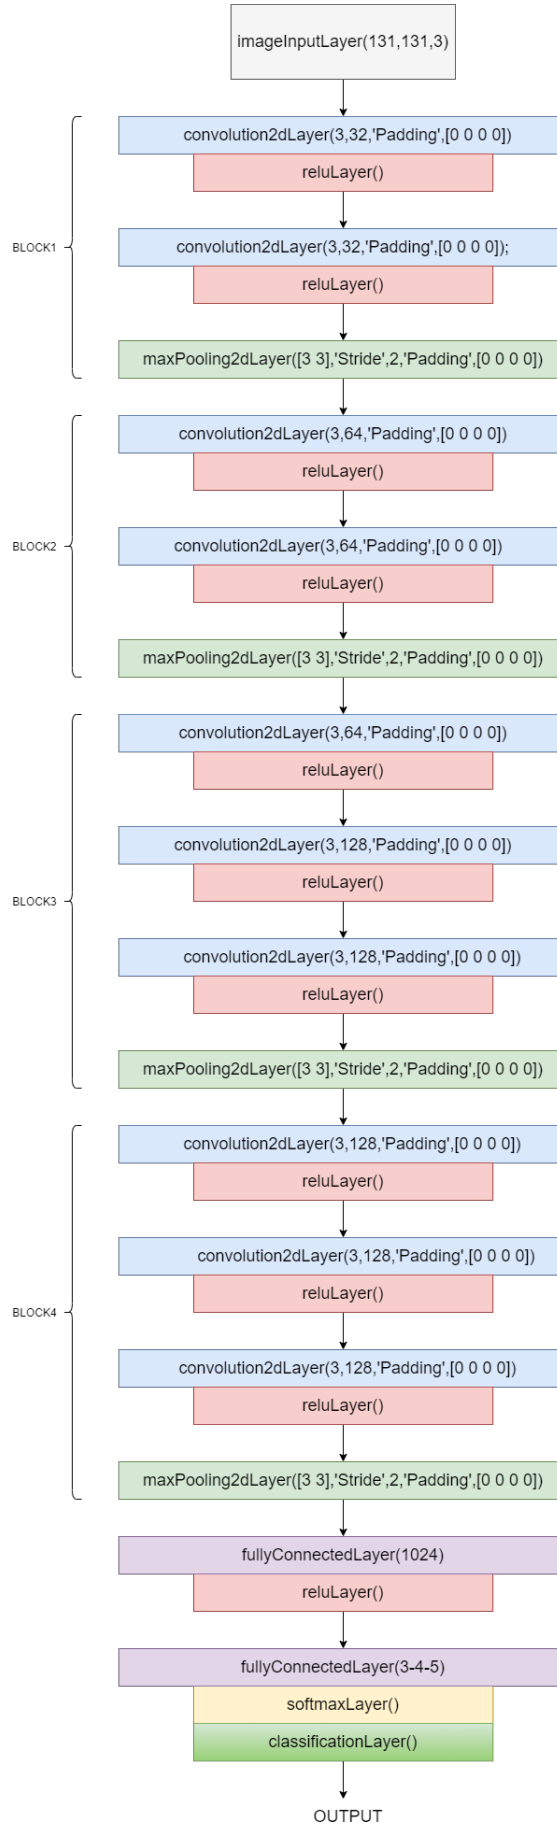
6 Sistem Tasarımı

Bu çalışmada yüksek sınıflandırma başarımı amacıyla farklı türde ağ yapılarıyla 2 model oluşturulmuştur. Oluşturulan model 131x131x3 boyutunda veri girişi almaktadır. Model VGG-16 mimarisi temel alınarak konvolüsyon katmanı, aktivasyon fonksiyonu, maksimum ortaklama katmanları bloklarından oluşmaktadır. Şekil 6.1 de modelin diyagramı verilmiştir. Aktivasyon fonksiyonu olarak hesaplama maliyeti az olan, kaybolan gradyanlar problemine karşı iyi performans gösteren relu fonksiyonu kullanılmıştır. Konvolüsyon katmanlarının tamamı, problem özelinde lokaldeki özelliklerin gözden kaçırılmaması önemli olduğu için 3x3 boyutunda filtrelerden oluşmaktadır. Filtre sayısı VGG modellerine kıyasla aşırı öğrenmenin engellenmesi, hesaplama maliyetinin azalması ve verisetlerinin yapısı dolayısıyla ciddi oranda azaltılmıştır. Ortaklama katmanları ise 3x3 boyutundadır ve diğer ortaklama tiplerinden daha iyi performans göstermesi dolayısıyla maksimum ortaklama tipindedir, kaydırma adımı (stride) 2'dir. Konvolüsyon ve ortaklama katmanları bloklarının ardından 1024 nöronlu tam bağlantı katmanı ile aktivasyon fonksiyonu relu gelmektedir. Son olarak sınıf sayısı adedinde nörona sahip tam bağlantı katmanı, softmax katmanı ve sınıflandırma katmanı gelmektedir. Modelde toplam 10 adet konvolüsyon katmanı ve 4 adet maksimum havuzlama katmanı kullanılmıştır. Modelin eğitim ayarları ise şöyledir: 10, 30, 50, 60, 75, 100 epoch sayısı denenmiştir ve sonuç olarak 50 epoch kullanılması kararlaştırılmıştır. Öğrenme oranı değeri için 0,0005 ve 0,00001 değerleri aralığındaki değerler sistematik olarak denenmiştir ve 0,0001 kullanılması kararlaştırılmıştır. Optimizasyon fonksiyonu olarak adaptif momentum ve momentum ile stokastik gradyan inişi denenmiş, momentum ile stokastik gradyan inişi kullanılması kararlaştırılmıştır. Ayrıca mini yığın boyutu olarak 4, 8, 16, 32, 64 değerleri denenmiştir. Yüksek mini yığın boyutlarının bellek kullanımı yüksektir ve modelin genelleştirmesinde az da olsa olumsuz etkisi vardır, bunun yanında çok düşük mini yığın boyutları da modelin gürültü öğrenmesine sebebiyet verebileceğinden dolayı mini yığın boyutu 16 olarak seçilmiştir. Buna ek olarak verisetinin dağılımından etkilenmemek, aşırı öğrenmeye engel olmaya yardım amacıyla her epoch verisetinin karıştırılması işlemi (shuffle) yapılmaktadır.

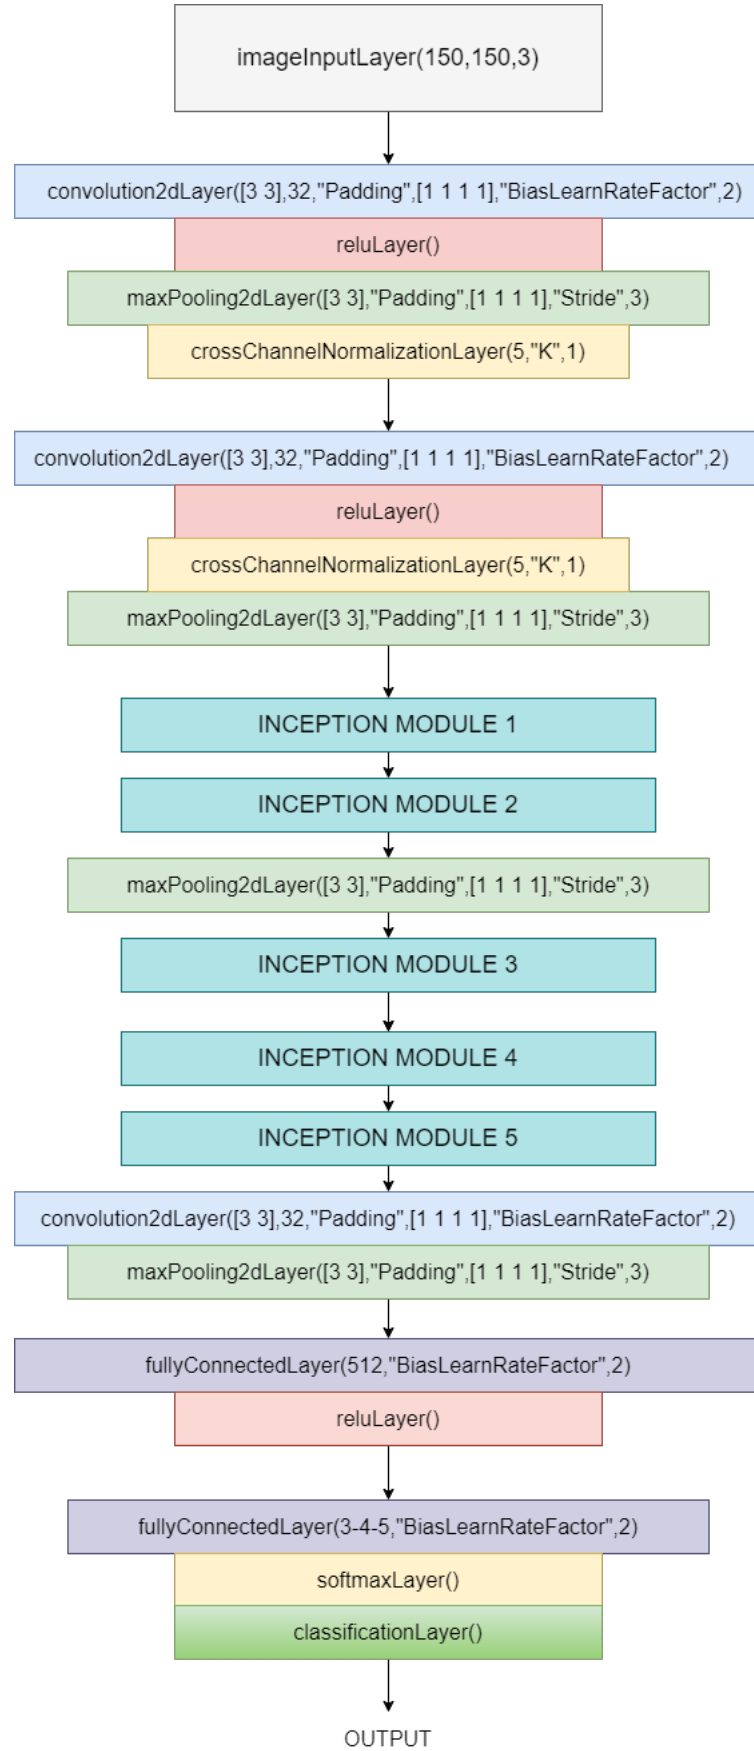
Oluşturulan ikinci model ise GoogLeNet mimarisi(Inception Network) temel alınarak oluşturulmuştur.Şekil 6.2 de modelin diyagramı verilmiştir.Model 150x150x3 boyutunda veri girişi almaktadır.Giriş katmanının ardından konvolüsyon-relu-kanallar arası normalleştirme(cross channel normalization)-maksimum ortaklama katmanlarından oluşan 2 adet blok içermektedir.Bu blokları takip eden 5 adet inception modülü ve 2. ve 3. modüller arasında maksimum ortaklama katmanına sahiptir.Inception modüllerinin diyagramı şekil 6.3 te verilmiştir.Inception modüllerinin arkasından son olarak konvolüsyon-maksimum ortaklama-tam bağlantı-relu-tam bağlantı-softmax-sınıflandırma katmanlarını içeren bir blok vardır.Modelde aktivasyon fonksiyonu olarak ilk modelle aynı şekilde relu kullanılmıştır.Inception modüllerinin dışındaki konvolüsyon ve maksimum ortaklama katmanlarında ilk modeldeki gibi 3x3 filtreler kullanılmıştır,fakat bu sefer 87 katmandan oluşan bu modelin hesaplama hızının artırılması amacıyla maksimum ortaklama katmanlarındaki kaydırma adımı 3 olarak seçilmiştir. Buna ek olarak inception modüllerindeki filtre sayıları ve dolgulama değerleri problemimize uygun olacak şekilde ayarlanmıştır. Modelin eğitim ayarları şu şekildedir: 10,30,50,60,75,100 epoch sayısı denenmiştir ve sonuç olarak 75 epoch kullanılması kararlaştırılmıştır.Öğrenme oranı değeri için 0,0001 ve 0,001 değerleri aralığındaki değerler sistematik olarak denenmiştir ve 0,001 kullanılması kararlaştırılmıştır.Optimizasyon fonksiyonu olarak adaptif momentum ve momentum ile stokastik gradyan inişi denenmiş,ilk modelin aksine adaptif momentum optimizasyon fonksiyonu olarak seçilmiştir.Mini-batch boyutu ilk modeldeki gibi 16 seçilmiştir.Bu modelin eğitiminde de her epoch verisetinin karıştırılması(shuffle) işlemi yapılmaktadır.Tablo 6.1 de modellerin hiperparametreleri verilmiştir.

	Network 1	Network 2
Epoch Num.	50	75
Learning Rate	0,0001	0,01
Optimizer	SGDM	ADAM
Mini Batch Size	16	16

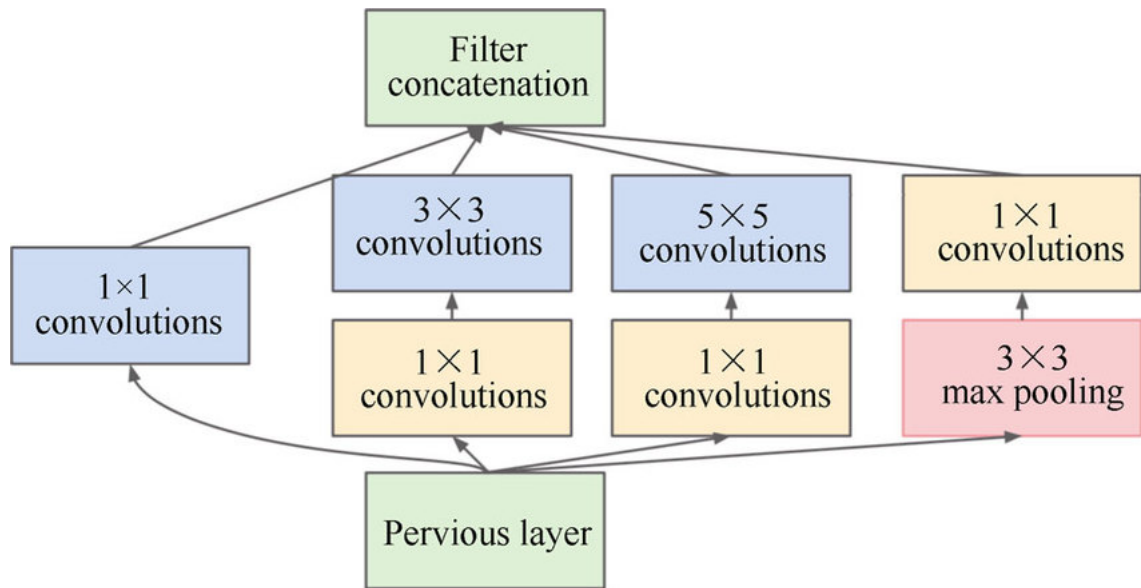
Tablo 6.1 Hyperparameters of Models



Şekil 6.1 Model 1



Şekil 6.2 Model 2




Şekil 6.3 Inception Module with Dimension Reduction

Ağlar üzerinde veri arttırma testleri uygulanarak, orjinal setlerin ve belirli oranda arttırılmış setlerin ağların başarımları üzerindeki etkileri incelenmiştir. HuSHeM verisetinde 1x(orjinal veri), 5x, 10x arttırılmış verisetleri, SMIDS verisetinde 1x, 5x, 8x arttırılmış verisetleri, SCIAN verisetinde 1x, 5x, 9x arttırılmış ve dengelenmiş verisetleri bu incelemede kullanılmıştır. Veri arttırma testlerinin sonucunda HuSHeM verisetinde verisetindeki örnek sayısının az olmasının da etkisiyle veri arttırma işlemlerinin her iki modelde de başarımları yaklaşık yüzde 10-15 gibi bir oranla ciddi bir şekilde arttırdığı görülmüştür. Lakin SMIDS ve SCIAN verisetlerinde veri arttırma işlemi başarımları yaklaşık yüzde 3 civarında arttırmıştır ve HuSHeM verisetine göre başarımları arttırmada daha etkisiz olmuştur. Aynı verisetinin eğitimlerinde başarımlar değişiklik gösterebileceğinden veri arttırma işleminin etkileri de benzer olarak değişiklik gösterebilmektedir. HuSHeM verisetinde verilerin dengesiz dağılımı dolayısıyla setlerin 1.ve 2. foldlarındaki başarımların diğer foldlara göre düşük olduğu görülmüştür. Modellerle göre incelendiğinde modellerin veri arttırma işlemlerine benzer tepkiler verdiği başarımlar arasındaki farkların düşük olduğu görülmüştür. Şekil 7.1 de SMIDS veri setinin, Şekil 7.2 de HuSHeM veri setinin, Şekil 7.3 te SCIAN veri setinin test sonuçları verilmiştir.


Oluşturulan evrişimli sinir ağları, epoch testleri yapılarak, 3 veriseti için ağın eksik öğrenmesine sebebiyet vermeyecek, aynı zamanda aşırı öğrenmeden ve gereksiz uzun eğitim sürelerinden kaçınılacak epoch değerlerinin bulunmasını sağlanmıştır. Elde edilen epoch değerleriyle ağların arttırılmış ve orjinal verisetlerindeki eğitim süreleri ölçülmüştür. Veri sayısının HuSHeM verisetinde az olması dolayısıyla ağların öğrenmesi için gerekli epoch sayısı bu verisetinde diğer verisetlerine göre daha fazla olduğu testler sonucunda görülmüştür. SCIAN ve SMIDS verisetlerinde veri sayısının yeterliliği sayesinde daha az epoch sayısında başarımların kolayca modelin potansiyeline yakınsadığı belirlenmiştir. Tablo 7.1 de ortalama eğitim süreleri verilmiştir.

	Network 1			Network 2		
Aug. Rate	HuSHeM	SMIDS	SCIAN	HuSHeM	SMIDS	SCIAN
1x	2 min	26 min	9 min	4 min	1hr 16 min	21 min
5x	9 min	2 hr 5 min	2 hr 21 min	19 min	5 hr 19 min	4 hr 47 min
8x	-	4 hr 1 min	-	-	8 hr 13 min	-
9x	-	-	4 hr 13 min	-	-	8 hr 12 min
10x	17 min	-	-	39 min	-	-


Tablo 7.1 Average Training Times



Şekil 7.1 SMIDS Test Sonuçları



Şekil 7.2 HuSHeM Test Sonuçları



Şekil 7.3 SCIAN Test Sonuçları

8 Sonuç

Bu projede oluşturulan iki farklı mimaride oluşturulan evrişimli sinir ağı modellerinin SMIDS,SCIAN,HuSHeM verisetleri üzerindeki başarımları ve eğitim süreleri ölçülmüştür.Verisetleri farklı oranlarda veri arttırma işlemlerine tabi tutularak modellerin verisetlerini ezberlemesinin engellenmesi,modellerin yetersiz veri nedeniyle öğrenememesinin önüne geçilmesi amaçlanmış ve yapılan testlerle orjinal verisetleri ve arttırılmış verisetleri üzerindeki başarımlar ve eğitim süresine olan etkileri gözlemlenmiştir. Bunun sonucunda veri arttırma işlemlerinin her iki modelde başarımlarında aynı etkiyi yarattığı görülmüştür.HuSHeM verisetinde örnek sayısının düşük olması,veri arttırma işlemlerinin etkisini arttırmış başarımları diğer verisetlerine göre yaklaşık yüzde 10 daha fazla arttırdığı görülmüştür.

İlk modelin ikinci modele göre özellikle orjinal veriyle yapılan testlerde az miktarda daha başarılı olduğu görülmüştür.Aynı zamanda ilk model daha düşük hesaplama maliyetine ve eğitim süresine sahiptir.

- 1- Imran Iqbal 1 , Ghulam Mustafa 2 and Jinwen Ma 1 ;Deep Learning-Based Morphological Classification of Human Sperm Heads;20 May 2020
- 2- Özkan İNİK,* Erkan ÜLKER;Derin Öğrenme ve Görüntü Analizinde Kullanılan Derin Öğrenme Modelleri;GAZİOSMANPAŞA BİLİMSEL ARAŞTIRMA DERGİSİ (GBAD) Gaziosman-pasa Journal of Scientific Research
- 3- Omer Lutfu Tortumlu, Hamza Osman Ilhan;The Analysis of Mobile Platform based CNN Networks in the Classification of Sperm Morphology;2020
- 4- Evrişimli Sinir Ağları el kitabı; <https://stanford.edu/~shervine/1/tr/teaching/cs-230/cheatsheet-convolutional-neural-networks>
- 5- Chang, V.; Garcia, A.; Hitschfeld, N.; Hartel, S. Gold-standard for computer-assisted morphological sperm analysis. *Comput. Biol. Med.* 2017, 83, 143–150.
- 6- Riordon, J.; McCallum, C.; Sinton, D. Deep learning for the classification of human sperm. *Comput. Biol. Med.* 2019, 111.
- 7- Shaker, F; Monadjemi, S.A.; Alirezaie, J.; Naghsh-Nilchi, A.R. A dictionary learning approach for human sperm heads classification. *Comput. Biol. Med.* 2017, 91, 181–190.
- 8- H. O. Ilhan, G. Serbes, and N. Aydin, “Automated sperm morphology analysis approach using a directional masking technique,” *Computers in Biology and Medicine*, p. 103845, 2020.
- 9- H. O. Ilhan, G. Serbes, and N. Aydin, “Dual tree complex wavelet transform based sperm abnormality classification,” in *2018 41st International Conference on Telecommunications and Signal Processing (TSP)*. IEEE, 2018, pp. 1–5.
- 10- H. O. Ilhan, I. O. Sigirci, G. Serbes, and N. Aydin, “The effect of nonlinear wavelet transform based de-noising in sperm abnormality classification,” in *2018 3rd International Conference on Computer Science and Engineering (UBMK)*. IEEE, 2018, pp. 658–661.
- 11- W. J. Yi, K. S. Park, and J. S. Paick, “Parameterized characterization of elliptic sperm heads

using fourier representation and wavelet transform,” 1998, vol. 20, no. 2, pp. 974–977.

12- L. Jiaqian, T. Kuo-Kun, D. Haiting, L. Yifan, Z. Ming, and D. Mingyue, “Human Sperm Health Diagnosis with Principal Component Analysis and K-nearest Neighbor Algorithm,” in *Medical Biometrics*, 2014 International Conference on, 2014, pp. 108–113.

13- F. Pérez-Sánchez, J. J. de Monserrat, and C. Soler, “Morphometric analysis of human sperm morphology,” *Int. J. Androl.*, vol. 17, no. 5, pp. 248–255, 1994.